



Universidade Federal Fluminense
Luís Felipe Ignácio Cunha

Questões em Bioinformática - Nível Básico

Algumas questões inspiradas pela plataforma:

<https://rosalind.info/problems/>

1. (Sequência de DNA) Dada uma string, retorne se ela é uma sequência de DNA, ou seja, para isso, todas as letras devem ser *A*, *C*, *G* ou *T*. Caso não seja, retorne as posições que os elementos diferem das possíveis letras.

Entrada: Uma string *s*.

Saída: Se *s* é uma sequência de DNA, retorne “sequência válida”, caso contrário, retorne as posições (sendo da posição 1 até a posição do tamanho da string *s*) que não possuem os valores esperados.

Exemplo 1:

acgctasdagctwqa

Sequência inválida, pois nas posições [7, 8, 13, 14] os elementos não possuem valores esperados

Exemplo 2:

acctctccta

Sequência válida

Exemplo 3:

sactg

Sequência inválida, pois na posição 1 o elemento não possui valor esperado

2. (Contagem de base nitrogenada) Dada uma string, retorne se ela é uma sequência de DNA. Caso não seja, retorne as posições que os elementos diferem das possíveis letras. Caso seja, retorne dizendo que ela é uma sequência de DNA juntamente com a quantidade de cada uma das possíveis letras *A*, *C*, *G*, *T*.

Entrada: Uma string *s*.

Saída: Se *s* é uma sequência de DNA, retorne “sequência válida”, juntamente com a quantidade de cada uma das possíveis letras *A*, *C*, *G*, *T*, caso contrário, retorne as posições (sendo da posição 1 até a posição do tamanho da string *s*) que não possuem os valores esperados.

Exemplo 1:

acgcacgtca

Sequência válida. Além disso, a contagem de cada base nitrogenada é: A: 3 C: 4 G 2 T: 1

3. (Transcrição DNA $\rightarrow$ RNA preservando caixa) Transcreva DNA para RNA substituindo T/t por U/u , preservando maiúsculas/minúsculas dos demais caracteres. Se houver letras fora de A, C, G, T (ignorando caixa), retorne “Sequência inválida” e as posições.

Entrada: Uma string s (DNA).

Saída: String transcrita para RNA ou mensagem de inválida.

Exemplo:

AcgtTa

AcguUa

4. (Descompressão RLE de DNA) Dada uma string RLE (formada por blocos letra+quantidade, p.ex. A3C2G1), reconstrua a sequência original. Valide se as letras são A, C, G, T e se as quantidades são inteiros positivos.

Entrada: String RLE.

Saída: Sequência expandida ou “Entrada inválida”.

Exemplo:

A3C2G1T1

AAACCGT

5. (Percentual de G+C por janela)

Dada uma sequência de DNA, queremos medir, em pequenos blocos (janelas) de tamanho k , qual a porcentagem de letras que são **G** ou **C**. Funciona assim: para cada bloco contínuo de k caracteres na sequência, conte quantas letras desse bloco são **G** ou **C** (a ordem não importa). Em seguida, calcule:

$$\text{Percentual} = \frac{\text{quantidade de G ou C no bloco}}{k} \times 100$$

Arredonde cada percentual para 2 casas decimais. Considere a sequência válida apenas se contiver somente as letras **A, C, G, T** (ignore maiúsculas/minúsculas). Se a sequência não for válida, escreva “Sequência inválida”. Se k for maior que o tamanho da sequência, não existem janelas.

Entrada: Um inteiro k e uma string s (DNA).

Saída: Uma lista com o percentual de G+C de cada janela (da posição 1 até $|s| - k + 1$), com 2 casas decimais; ou a mensagem “Sequência inválida”.

Exemplos:

- $k = 3$
 $s = \text{ACGACG}$

Janelas: ACG, CGA, GAC, ACG.

Cada janela tem 2 letras em {G, C}.

Saída: [66.67, 66.67, 66.67, 66.67]

- $k = 3$
 $s = \text{CGC}$

Janela: CGC (3 letras em {G, C}).

Saída: [100.00]

6. (Reversão de Sequência) Dada uma sequência de DNA, obtenha sua sequência reversa. Uma sequência reversa de uma string s possui os elementos listados primeiro escrevendo o elemento na última posição, depois na penúltima posição e assim sucessivamente até escrever o elemento na primeira posição.

Entrada: Uma string s .

Saída: Sequência reversa de s .

Exemplo 1:

asdasd

dsadsa

7. (Reverso Complementar) Dada uma sequência de DNA, obtenha seu complemento reverso. Cada base nitrogenada do DNA possui seu complemento, a saber $A \rightarrow T$, $T \rightarrow A$, $C \rightarrow G$, $G \rightarrow C$. Assim, o complemento reverso de uma sequência de DNA s é obtido das seguintes etapas: obtenha a sequência reversa de s , seja s' essa sequência resultante; substitua cada elemento de s' pelo seu complemento.

Entrada: Uma string de DNA s .

Saída: Sequência s e seu reverso complementar, caso s seja uma sequência de DNA. Caso contrário, retorne que esta é uma sequência inválida.

Exemplo 1:

acgctagctagc

Dada a sequência ACGCTAGCTAGC, seu reverso complementar é: GCTAGCTAGCGT

Exemplo 2:

acgctagasd

Sequência inválida

8. (Distância de Hamming) Dadas duas strings s e t de mesmo tamanho, a *distância de Hamming* entre s e t , denotado por $d_H(s, t)$ é o número de símbolos numa mesma posição que diferem entre s e t .

Entrada: Duas strings s e t .

Saída: Se as strings são strings de DNA (cujas letras são A, C, G ou T) e se possuem o mesmo tamanho, retorne $d_H(s, t)$. Se uma das strings não for string de DNA, então retorne dizendo que uma das sequências não é string de DNA. Caso as strings de DNA não sejam de mesmo tamanho, retorne dizendo que os genomas devem possuir o mesmo tamanho.

Exemplo 1:

acftg

fcgat

Uma das sequências não é sequência de DNA

Exemplo 2:

acgtgcta

ctaaacga

Distância de Hamming entre ACGTGCTA e CTAAACGA é: 6

9. (Motif) Considere um DNA por uma sequência do alfabeto A, C, G, T , associando as bases nitrogenadas Adenina, Citosina, Guanina ou Timina, respectivamente. Considere também um *motif* por um intervalo de nucleotídeos (ou de aminoácidos, em proteínas) que possui alguma importância biológica. Queremos obter todas as substrings “mais próximas” do motif. Neste problema, “mais próxima” é definida pela *distância de Hamming* de duas substrings de mesmo tamanho.

Entrada: Um inteiro não negativo k , onde $k \leq 50$, uma string s de mofit, com no máximo 50 caracteres, e uma string t de DNA, com no máximo 500 caracteres.

Saída: Todas substrings t' de t tal que a distância de Hamming entre t' e s seja no máximo k . Cada substring deve ser codificada na sua saída pela posição inicial em t seguida pelas posições onde t' e s diferem. Se as entradas estiverem fora dos valores delimitados, então escreva “Valores não estão de acordo”.

Exemplo 1:

```
3
ACGTAG
ACGGATCGGCATCGT
```

As substrings com distância no máximo 3 do mofit e as posições são:

```
1 4 6
9 1 3 5
```

Exemplo 2:

```
3
acgctgctcga
cgata
```

Valores não estão de acordo

10. (Splicing) Em *Splicing de RNA*, descrevemos o processo pelo qual os exons são separados de uma molécula de pre-mRNA e remontados para produzir um mRNA final para fins de tradução de proteínas. Considere o problema onde é apresentada uma sequência de pre-mRNA com n exons e ao juntar pelo menos k dos n exons, na mesma ordem que é apresentada no pre-mRNA, conseguimos criar uma molécula final de mRNA (veja Figura 1 para uma ilustração).




Figura 1: Processo de splicing com 4 exons e dois exemplares formados com 3 exons.

Assim, dados k e n , onde $k \leq n$, desejamos saber quantos são os possíveis moléculas finais de mRNA com pelo menos k exons.

Entrada: Inteiros positivos n e k , onde $k \leq n$.

Saída: Quantidade de possíveis moléculas finais de mRNA com pelo menos k exons dados n exons no pre-mRNA.

Exemplo 1:

```
6
2
```

A quantidade de mRNAs com pelo menos 2 exons dentre os 6 exons é: 42.0

11. (Substrings Distintas) Dada uma sequência de DNA válida (contendo apenas A, C, G e T), escreva um programa que conte o número de substrings distintas de tamanho k na sequência. Caso a sequência não seja válida, retorne "Sequência inválida".

Entrada: Um inteiro k e uma string s representando uma sequência de DNA.

Saída: O número de substrings distintas de tamanho k , ou a mensagem de sequência inválida se s não for uma sequência de DNA.

Exemplo 1:

3
ACGACGTAG

6

12. (Substrings de tamanho e quantidade determinadas) Dada uma sequência de DNA válida (contendo apenas A, C, G e T), escreva um programa que encontre todas as substrings de tamanho k que aparecem ao menos n vezes. Caso a sequência não seja válida, retorne "Sequência inválida".

Entrada: Dois inteiros k e n , seguidos de uma string s representando a sequência de DNA.

Saída: Liste todas as substrings de tamanho k que aparecem ao menos n vezes, uma por linha, ou a mensagem "Sequência inválida".

Exemplo 1:

3
2
ACGACGTAGACG

ACG

GAC

13. (Quebra em códons e contagem de um códon) Se s é DNA válido e $|s|$ é múltiplo de 3, quebre s em uma lista de códons *não sobrepostos* a partir da primeira posição. Dado um códon alvo c (válido), conte quantas vezes c aparece exatamente como um elemento dessa lista. Não conte ocorrências de c que atravessem a fronteira entre dois códons.

Entrada: s e um códon c .

Saída: Lista de códons e a contagem de c ; ou mensagem de inválida/múltiplo de 3.

Exemplo 1:

ATGACGACG
ACG

[ATG, ACG, ACG], Contagem de ACG: 2

Exemplo 2:

ATGACGACG
GAC

[ATG, ACG, ACG], Contagem de GAC: 0 (*GAC existe como substring, mas cruza a fronteira de códons*)