


Aula 1: Fundamentos biológicos e modelagem computacional

Luís Felipe

UFF

13 de Agosto de 2026

Da célula à proteína




National Human Genome Research Institute - NHGRI, *Gene Expression*, 2023.

<https://www.genome.gov/genetics-glossary/Gene-Expression>

1. O **DNA** permanece no núcleo.
2. Um **gene** é transcrito e o RNA é processado.
3. O mRNA maduro é exportado.
4. Um **ribossomo** o traduz em uma cadeia de aminoácidos.


A figura mostra uma célula eucariótica: núcleo e citoplasma separam as etapas.

Dogma central: a informação muda de suporte




RNA processing


Primary RNA transcript



Spliced RNA



Translation



Dogma central da biologia molecular

No fluxo usual de expressão de um gene codificante, uma região de DNA é transcrita em RNA; o RNA mensageiro é então traduzido em uma sequência de aminoácidos.

Transcrição: DNA $\rightarrow$ RNA.

Processamento: pré-mRNA $\rightarrow$ mRNA maduro.

Tradução: códons do mRNA $\rightarrow$ aminoácidos.

Ideia-chave


O DNA não é convertido fisicamente em proteína. A informação é copiada e reinterpretada em etapas.

Onde está o DNA? Do cromossomo à dupla hélice

Cromossomo

Em células eucarióticas, cada cromossomo nuclear contém uma longa molécula de DNA associada a proteínas.


- o DNA precisa ser compactado para caber no núcleo;
- No núcleo, o DNA se enrola em proteínas chamadas **histonas**, formando nucleossomos.
- O conjunto dessa organização constitui a **cromatina**.



<https://www.genome.gov/about-genomics/fact-sheets/Chromosomes-Fact-Sheet>

O **genoma** corresponde ao conjunto completo de sequências de DNA de um organismo, distribuídas em um ou mais cromossomos.

Um gene é uma região funcional do genoma



Um gene ocupa uma região da molécula de DNA; não corresponde ao cromossomo inteiro.

Gene

Um **gene** é uma região do genoma cuja expressão produz um produto funcional.

Em genes de RNA não codificante, o produto é um **RNA funcional**.

Em genes codificantes de proteína, um mRNA é traduzido em uma cadeia de aminoácidos, chamada **polipeptídeo**.


- o genoma contém genes, regiões regulatórias, sequências estruturais e outras regiões não codificantes;
- nem todo gene codifica uma proteína: alguns produzem RNAs que são, eles próprios, funcionais;
- regiões regulatórias e proteínas reguladoras ajudam a determinar em quais células, quando e em que intensidade cada gene é transcrito.

Transcrição: produzir uma cópia em RNA

O que acontece?

A **RNA polimerase** abre localmente a dupla hélice, usa uma das fitas do DNA como molde e produz uma cadeia complementar de **pré-mRNA**.


- apenas uma região é copiada;
- o DNA se abre somente perto da enzima (RNA polimerase);
- o RNA cresce no sentido 5' → 3';
- atrás da polimerase, o DNA volta a parear.



<https://openstax.org/books/biology-2e/pages/15-2-prokaryotic-transcription>

O RNA é complementar à fita molde e quase idêntico à fita codificadora, com U no lugar de T.

Processamento: do pré-mRNA ao mRNA maduro



Três transformações principais


1. adição do **cap 5'**;
2. remoção de íntrons e união dos éxons;
3. adição da **cauda poli(A)** em 3'.

O mRNA maduro é então exportado do núcleo para o citoplasma.

Consequência computacional

O mRNA pode concatenar intervalos separados no DNA genômico.

Tradução: o ribossomo lê o mRNA em códons



Como ler a figura


- o ribossomo percorre o mRNA de 5' para 3';
- cada tRNA reconhece um códon e traz o aminoácido correspondente;
- ligações peptídicas fazem a cadeia crescer até um códon de parada.

O códon de início estabelece o quadro de leitura.

Três operações sobre sequências

Do gene ao polipeptídeo:

1. **Transcrição:** produz uma cadeia complementar de RNA.
2. **Splicing:** remove intervalos e concatena os segmentos retidos.
3. **Tradução:** agrupa o mRNA em trincas e muda do alfabeto de nucleotídeos para o de aminoácidos.



<https://www.genome.gov/genetics-glossary/Gene>

A ponte para Computação

Em cada etapa, precisamos decidir o que a representação preserva: símbolos, ordem, orientação e relações entre intervalos.

Os quatro níveis descrevem aspectos diferentes da proteína


Proteína: Molécula formada por uma ou mais cadeias de aminoácidos, ligadas por ligações peptídicas e organizadas de modo a desempenhar uma função biológica.

Primária: sequência de aminoácidos.

Secundária: dobramentos locais, como hélices α e folhas β .

Terciária: conformação tridimensional de uma cadeia.


Quaternária: associação de duas ou mais cadeias.



Importante

Nem toda proteína possui estrutura quaternária. Ex.: Mioglobina, proteína encontrada nos músculos (mantém oxigênio disponível dentro dos músculos).

A primeira abstração preserva ordem e perde contexto



Preservamos:

- identidade dos símbolos;
- ordem;
- orientação, quando definida.

Não representamos automaticamente:

- dobramento e interações;
- regulação e abundância;
- incerteza experimental.

A escala vai da célula às bases



Em eucariotos

A maior parte do DNA está no núcleo, organizada em cromossomos.

Em procariontes

O DNA fica no nucleóide, sem uma membrana nuclear.

DNA é uma molécula e também uma sequência

A mesma palavra “sequência” pode descrever objetos em escalas muito diferentes.

Como molécula

O **ácido desoxirribonucleico** é um polímero de desoxirribonucleotídeos, normalmente organizado como uma dupla hélice antiparalela.

- esqueleto açúcar–fosfato;
- bases (A,C,G,T);
- moléculas lineares ou circulares;
- replicação e transmissão hereditária.

Como representação

Uma das fitas pode ser escrita como


$$S = \text{ACGTTGCA} \in \{A, C, G, T\}^*.$$

Essa string registra identidade, ordem e orientação das bases. Ela não é a própria molécula nem descreve automaticamente cromatina, expressão ou erros de medição.

Um nucleotídeo reúne base, açúcar e fosfato

Um **nucleotídeo** é a unidade básica do DNA e do RNA, formada por um açúcar, um grupo fosfato e uma base nitrogenada. A sequência dessas bases armazena a informação genética.

1. **base nitrogenada**;
2. **pentose**, um açúcar de cinco carbonos;
3. um ou mais **grupos fosfato**.




Bases


Purinas: adenina (A) e guanina (G).

Pirimidinas: citosina (C), timina (T) e uracila (U).

No DNA, a pentose é a desoxirribose e aparece timina.
No RNA, a pentose é a ribose e aparece uracila.



Nucleosídeo, nucleotídeo e cadeia são objetos diferentes




Obs.: O alfabeto registra a base que varia em cada posição. O esqueleto açúcar–fosfato, repetido ao longo da cadeia, fica implícito na representação por string.

A ligação química dá direção à cadeia

Ligação fosfodiéster

O fosfato conecta o carbono 5' de um nucleotídeo ao grupo 3'-OH do nucleotídeo anterior.

- uma extremidade é chamada 5';
- a outra é chamada 3';
- polimerases acrescentam nucleotídeos ao 3'-OH;
- por isso, a nova cadeia cresce em 5' $\rightarrow$ 3'.



P: grupo fosfato;

S: açúcar (*sugar*);

A, T, C, G: bases nitrogenadas.

A dupla hélice combina complementaridade e antiparalelismo

Pareamento


No DNA, *A* pareia com *T*, e *C* pareia com *G*, por ligações de hidrogênio.

Antiparalelismo

As duas fitas têm sentidos opostos:

5'	ACGTT	3'
3'	TGCAA	5'

Conhecendo uma fita, a outra é determinada pela complementaridade, mas deve ser escrita no sentido correto.



O inverso complementar é uma operação sobre strings

Se

$$S = \text{ACGTT},$$

primeiro substituímos cada base por sua complementar:

$$\text{comp}(S) = \text{TGCAA}.$$

Essa sequência está orientada de 3' para 5'. Para escrevê-la na convenção 5' → 3', invertamos a ordem:

$$\text{rc}(S) = \text{AACGT}.$$

Consequência algorítmica

Reads e padrões podem vir de qualquer fita. **Busca**, **indexação** e **alinhamento** precisam considerar as duas orientações ou usar uma codificação canônica.

O código genético mapeia 64 códons para sinais de tradução

Um **aminoácido** é uma das unidades que formam as proteínas; durante a tradução, cada **códon** do mRNA especifica o aminoácido que será incorporado à cadeia polipeptídica ou sinaliza sua parada.

Códon

Trinca consecutiva de nucleotídeos do mRNA interpretada pelo sistema de tradução em um quadro de leitura.

Como há quatro bases (A, C, G, U), existem

$$4^3 = 64 \text{ códons.}$$

- 61 especificam aminoácidos;
- 3 são códons de parada: UAA, UAG e UGA;
- AUG codifica metionina e é o códon de início mais comum.

Duas propriedades

Código degenerado: vários códons podem especificar o mesmo aminoácido.

Quase universal: em quase todos organismos, mesmos códons especificam os mesmos aminoácidos, com exceções conhecidas.

O quadro de leitura decide como a string é dividida

Para o RNA

AUGGCCAUUGAA,

há três possíveis deslocamentos iniciais:

0 : AUG GCC AUU GAA

1 : UGG CCA UUG AA


2 : GGC CAU UGA A.

Uma mesma sequência produz agrupamentos diferentes, e portanto interpretações diferentes, conforme o deslocamento.

Em DNA dupla fita, uma busca computacional pode considerar três quadros em cada orientação: **seis quadros**.

DNA associado a proteínas forma a cromatina dos eucariotos

- DNA enrola-se em histonas;
- nucleossomos organizam a cromatina;
- alças e níveis adicionais compactam a molécula;
- na divisão, a cromatina pode atingir alta condensação.




A forma X

Ela representa duas cópias do mesmo cromossomo, chamadas **cromátides-irmãos**, produzidas pela replicação e ainda unidas.

O genoma é organizado em cromossomos, mas sua sequência varia

Genoma

O **genoma** é o conjunto completo do DNA de um organismo, distribuído em seus cromossomos.




- indivíduos da mesma espécie compartilham a organização geral do genoma;
- isso não significa que suas sequências de DNA sejam idênticas;
- em organismos diploides, até as duas cópias de um mesmo tipo de cromossomo podem apresentar diferenças.

Comparar genomas

Comparamos **regiões homólogas**, derivadas de uma mesma região ancestral, mas que podem diferir em bases, pequenos trechos, número de cópias ou organização.

Genomas da mesma espécie também diferem

- **SNV**: substituição de uma base;
- **indel**: inserção ou deleção curta;
- **variação de cópia**: ganho ou perda de segmentos;
- **variante estrutural**: deleção, duplicação, inversão, inserção ou translocação de regiões maiores.



Para comparar

Precisamos decidir a escala: bases, genes, blocos conservados, cromossomos completos ou caminhos em um grafo.

Genômica comparativa: mudanças em várias escalas

Genômica comparativa é a área que compara genomas ou regiões homólogas para investigar conservação, variação, função e evolução.

Escala de bases: dentro de genes

Genes homólogos podem diferir por:

- substituições de bases;
- inserções;
- deleções.

A **distância de edição**, ou distância de **Levenshtein**, é o menor número dessas operações necessário para transformar uma sequência na outra.

$$\text{ACGT} \xrightarrow{1 \text{ deleção}} \text{AGT} \quad d_L = 1$$

Escala de genes ou blocos


Os genomas podem diferir quanto a:

- presença e número de cópias;
- ordem dos genes ou blocos;
- orientação;
- organização em cromossomos.

Essas diferenças podem resultar de ganhos, perdas, duplicações, inversões e translocações.

$$(+1, +2, +3, +4) \longrightarrow (+1, -3, -2, +4)$$

Blocos orientados substituem milhões de bases por símbolos




Modelo

Cada símbolo representa uma região homóloga ou um bloco conservado. A ordem registra posição relativa; o sinal registra orientação em relação à convenção escolhida.

Hipótese a explicitar

No modelo básico, cada bloco pode aparecer uma vez em cada genoma. Duplicações e perdas exigem versões mais gerais.

Cabeça e cauda transformam vizinhança em adjacência



Um bloco possui duas extremidades abstratas:


- cauda a^t ;
- cabeça a^h .

Uma **adjacência** é um par de extremidades que se tocam no cromossomo. Em cromossomos lineares, extremidades não pareadas são telômeros; em circulares, toda extremidade pertence a uma adjacência.

Por que fazer isso?

Operações de rearranjo podem ser descritas como cortes e reconexões de adjacências, sem retornar às coordenadas de cada base.

Uma inversão muda ordem, orientação e duas adjacências



$$(1^h, 2^t), (3^h, 4^t) \longrightarrow (1^h, 3^h), (2^t, 4^t).$$

Antecipação da Aula 5

A operação DCJ formaliza o corte de duas adjacências e a reconexão das quatro extremidades. Distância, ordenação e consenso serão estudados depois.

A escala escolhida determina o objeto do algoritmo

Escala	Representação	Preserva principalmente
bases	string	substituições, inserções, deleções e padrões locais
genes	intervalos anotados	posição, orientação e conteúdo funcional
blocos	permutação com sinais	ordem relativa e inversões
adjacências	conjunto ou grafo	vizinhança e estrutura cromossômica
pangenoma	caminhos em grafo	alternativas presentes em uma população

Princípio de modelagem


Não existe a representação “mais fiel” em absoluto. Existe a representação que preserva o que a pergunta precisa e descarta o restante de modo controlado.

Cada pergunta escolhe objeto, operação e custo

Pergunta biológica	Objeto	Operação ou problema
Onde ocorre um padrão?	string de DNA/RNA	busca e indexação
Quão semelhantes são duas sequências?	duas strings	alinhamento e distância de edição
Qual sequência explica fragmentos?	conjunto de reads	montagem e superstring
Como dois genomas diferem em ordem?	blocos orientados	distância de rearranjo
Qual árvore resume várias hipóteses?	árvores/grafos	consenso e otimização



As próximas aulas partem destas escolhas



- Strings usarão alfabetos, orientação, complemento reverso, alinhamento e padrões.
- Genômica comparativa usará cromossomos, blocos orientados, extremidades e adjacências.
- Complexidade perguntará quais versões desses problemas admitem algoritmos eficientes.

As definições biológicas restringem quais entradas, operações e soluções fazem sentido.


Leituras para consolidar

1. Setubal, J. C.; Meidanis, J. *Introduction to Computational Molecular Biology*, Cap. 1.
2. Alberts, B. et al. *How Cells Read the Genome: From DNA to Protein*. NCBI Bookshelf.
3. OpenStax. *Biology 2e*, Secs. 3.4 e 3.5.
4. NHGRI. Glossário: DNA, gene, chromosome, genome e comparative genomics.
5. Pevzner, P. A. *Computational Molecular Biology*: introdução aos rearranjos de genomas.

Prioridade

Para a próxima aula de strings, revise orientação, complemento reverso, gene, mRNA, códon e quadro de leitura. Para a Aula 5, revise blocos orientados e adjacências.

Apêndice: o dogma central não é apenas uma seta linear




Formulação precisa

O dogma central trata da transferência de informação sequencial entre classes de polímeros. Replicação de DNA, replicação de RNA e transcrição reversa são compatíveis com essa formulação.

Proteínas podem regular DNA e RNA, mas isso não significa copiar a sequência de uma proteína de volta para um ácido nucleico.

Apêndice: um gene pode originar mais de um produto



Splicing alternativo

Combinações diferentes de éxons geram isoformas distintas de RNA e, em genes codificantes, podem gerar proteínas diferentes.

A relação gene $\rightarrow$ RNA $\rightarrow$ proteína não é necessariamente um para um.