

Aula 5: Genômica comparativa, rearranjos e DCJ

Luís Felipe

UFF

27 de Agosto de 2026

Comparar bases e comparar organização respondem perguntas diferentes

Escala da sequência

Comparamos nucleotídeos dentro de regiões homólogas:

ACGTTAC ACGCTAC.

Alinhamento e distância de edição descrevem substituições e pequenos indels.

Como transformar **mudanças cromossômicas** em **operações combinatórias** e calcular o menor número de operações entre dois genomas?

Escala da organização


Comparamos a ordem e a orientação de regiões maiores:

$(+1, +2, +3, +4)$

$(+1, -3, -2, +4)$.

Aqui, o conteúdo é o mesmo, mas um segmento foi invertido.

Blocos conservados transformam regiões longas em símbolos



Bloco conservado

Região homóloga reconhecida nos genomas comparados. Pode representar um **gene**, um conjunto de genes ou um segmento maior.

Consideramos que os blocos orientados são dados de entrada.

Hipóteses do modelo básico


- os dois genomas possuem os mesmos n blocos;
- cada bloco aparece uma vez;
- o sinal registra sua orientação;
- diferenças internas aos blocos são abstraídas.

Rearranjos mudam a estrutura dos cromossomos

Evento	Efeito
inversão	um segmento reaparece em ordem e orientação reversas
translocação	segmentos são trocados entre cromossomos
fusão	dois cromossomos formam um
fissão	um cromossomo é dividido em dois

Rearranjos balanceados

Esses eventos podem preservar o conjunto de blocos, alterando apenas sua organização. Deleções e duplicações exigem modelos adicionais.



Exemplo de translocação recíproca: dois cromossomos trocam segmentos.

Uma inversão real pode interromper um gene

Exemplo: gene *F8*


Uma recombinação entre cópias homólogas da região *int22h* pode inverter um segmento que contém os éxons 1–22 de *F8*.

- o segmento reaparece invertido;
- as partes do gene deixam de formar uma unidade contínua;
- a inversão do íntron 22 é uma causa frequente de hemofilia A grave.



No modelo por blocos: a inversão reverte a ordem do segmento e troca os sinais dos blocos afetados.

O cromossomo Filadélfia é adquirido durante a vida



© 2024 Terese Winslow
U.S. Govt. has certain rights

O evento

A translocação $t(9;22)$ reconecta partes dos cromossomos 9 e 22 e produz o gene de fusão *BCR::ABL1*.

Alteração adquirida


Em geral, essa alteração é **somática e adquirida**: surge em uma célula formadora do sangue durante a vida e fica restrita ao clone descendente de células anormais. Não está presente em todas as células e não é, em geral, herdada dos pais.

Consequência

A proteína BCR::ABL1 possui atividade tirosina-quinase anormal e favorece a expansão do clone, podendo levar à leucemia mieloide crônica.

O cromossomo humano 2 preserva sinais de uma fusão

Figure 21.12a



(a) Human and chimpanzee chromosomes

Herança evolutiva

Duas regiões correspondentes a cromossomos que permanecem separados nos outros grandes primatas aparecem unidas no cromossomo humano 2.

- há sequências semelhantes a telômeros no sítio interno de fusão;
- há vestígios de um segundo centrômero, hoje inativo;
- a fusão reduziu em um o número haploide de cromossomos nessa linhagem.

Fusão e **fissão** deixam assinaturas observáveis e comparáveis entre genomas. A figura usa a numeração antiga 12/13; esses cromossomos também são chamados 2A/2B.

A distância permite reconstruir genomas ancestrais

Genomas ancestrais não podem ser sequenciados diretamente. Conhecemos apenas a organização dos genomas das espécies atuais.

O problema computacional

Dados os genomas atuais

$$G_1, G_2, \dots, G_k,$$


procuramos um **genoma ancestral** candidato M que minimize a soma das distâncias:

$$M^* = \arg \min_{\text{genoma candidato } M} \sum_{i=1}^k d(M, G_i).$$

Obs.:

- **min** fornece o menor **valor** da soma;
- **arg min** fornece o **genoma** que produz esse valor mínimo.

A




Gao et al. (2022) reconstruíram o **ancestral comum de *Brassica rapa* e *Brassica oleracea*** (tipo de crucíferos), utilizando *B. nigra* como grupo externo. O ancestral inferido possuía nove cromossomos. Foram estimadas:

- 25 fissões e 24 fusões até *B. rapa*;
- 27 fissões e 27 fusões até *B. oleracea*.

A **distância** permite comparar diferentes **genomas ancestrais candidatos**.

Repolho e nabo motivaram a comparação por rearranjos

Hannenhalli e Pevzner (1998) retomaram um caso de genomas mitocondriais de *Brassica oleracea* (repolho) e *Brassica campestris* (nabo): muitos genes eram 99%–99,9% idênticos, mas a ordem gênica diferia fortemente.



buscar uma sequência mínima que transforme uma ordem na outra

O que os símbolos representam?

Cada número representa um dos cinco grandes blocos conservados, contendo vários genes. O desenho omite as orientações para destacar somente a ordem.

Parcimônia fornece uma hipótese mínima, não a história completa

Observamos os genomas atuais, mas **não observamos diretamente todos os eventos que ocorreram desde o ancestral comum.**

Princípio de parcimônia

Fixado um modelo de operações, preferimos um cenário que explica os genomas com o menor número de eventos. **A distância é esse número mínimo.**

O que o mínimo oferece?

- um limite inferior para o número de eventos;
- uma medida reproduzível de dissimilaridade;
- cenários candidatos para inspeção biológica;
- custos para métodos filogenéticos e de reconstrução ancestral.

O que ele não garante?

- que o caminho mínimo foi o caminho real;
- que todos os eventos têm a mesma frequência;
- que não houve reversões recorrentes, perdas ou duplicações;
- que a árvore inferida independe do modelo escolhido.

Um bloco é um marcador orientado

O que pode ser um bloco?

Um bloco pode ser um **gene ortólogo** ou uma **região de sintenia conservada** contendo vários genes. O requisito é possuir uma correspondência entre os genomas comparados e uma orientação conhecida.



um bloco de sintenia com vários genes

Hipótese do modelo básico

Usaremos blocos $1, \dots, n$, cada um aparecendo exatamente uma vez em cada **genoma**. Os algoritmos recebem os blocos já identificados; descobrir esses blocos é **outra** etapa computacional.

Cromossomo vs genoma

Cromossomo

Uma sequência de blocos orientados, por exemplo

$$C_1 = \langle +1, +2, -3, +4 \rangle.$$

Os sinais descrevem a orientação de cada bloco no cromossomo.

Genoma



Uma coleção de cromossomos, por exemplo

$$G = \{C_1, C_2, \dots, C_k\}.$$

Assim, $G = \{C_1\}$ é um genoma unichromossômico, não a identificação entre os dois conceitos.


Extremidade do bloco versus telômero

Todo bloco i possui duas extremidades abstratas, i^t (*tail*) e i^h (*head*). Elas só representam telômeros quando aparecem como extremidades livres de um cromossomo linear.



Genoma com um cromossomo vira adjacências e telômeros

Considere o cromossomo $C_1 = \langle +1, +2, -3, +4 \rangle$ e o genoma $G = \{C_1\}$.



Partes do genoma

$$\text{Part}(G) = \{\{1^t\}, \{1^h, 2^t\}, \{2^h, 3^h\}, \{3^t, 4^t\}, \{4^h\}\}.$$

Pares são **adjacências**; singletons são **telômeros**. Cada extremidade ocorre em exatamente uma parte.

O mesmo modelo representa genomas multichromossômicos

Considere dois cromossomos lineares:

$$G = \{\langle +1, -2, +3 \rangle, \langle -4, +5 \rangle\}.$$

$$C_1 \quad \boxed{+1} \quad \boxed{-2} \quad \boxed{+3}$$

$$C_2 \quad \boxed{-4} \quad \boxed{+5}$$

$$\text{Part}(G) = \{\{1^t\}, \{1^h, 2^h\}, \{2^t, 3^t\}, \{3^h\}, \\ \{4^h\}, \{4^t, 5^t\}, \{5^h\}\}.$$

Adjacências

$$\text{Adj}(G) = \{\{1^h, 2^h\}, \{2^t, 3^t\}, \{4^t, 5^t\}\}.$$

Telômeros

$$\{1^t\}, \{3^h\}, \{4^h\}, \{5^h\}.$$

Quatro telômeros representam dois cromossomos lineares.

A distância depende das operações permitidas

Para um conjunto de operações $\mathcal{O}$, definimos

$$d_{\mathcal{O}}(A, B) = \min\{k : \text{uma sequência de } k \text{ operações de } \mathcal{O} \text{ transforma } A \text{ em } B\}.$$

Duas saídas relacionadas

- **distância:** o menor número k de eventos;
- **ordenação:** uma sequência mínima de operações que realiza a transformação.

Como isso é usado?

Distâncias entre vários pares de genomas formam uma matriz que pode alimentar **métodos de agrupamento** ou **reconstrução filogenética**. As sequências de operações sugerem cenários candidatos e auxiliam a **reconstrução de genomas ancestrais**.

Obs.: Contar apenas inversões, contar SCJ ou contar DCJ produz distâncias diferentes. O conjunto $\mathcal{O}$ deve representar os eventos e as escalas relevantes para os dados.

Um corte SCJ pode separar um cromossomo em dois

Single-Cut-or-Join


corte: $\{p, q\} \longrightarrow \{p\}, \{q\}$, junção: $\{p\}, \{q\} \longrightarrow \{p, q\}$.

Comece com

$$G = \{\langle +1, +2, +3, +4 \rangle\}.$$

Corte a adjacência $\{2^h, 3^t\}$:

$$\{2^h, 3^t\} \longrightarrow \{2^h\}, \{3^t\}.$$



$$G' = \{\langle +1, +2 \rangle, \langle +3, +4 \rangle\}.$$

Contagem dos telômeros: Antes havia 2 telômeros; depois há 4. No modelo, as extremidades do corte tornam-se telômeros.

Para SCJ, registrar as adjacências é suficiente

Com um conjunto fixo de extremidades, os telômeros são exatamente as extremidades que não participam de nenhuma adjacência. Portanto, $\text{Adj}(G)$ determina $\text{Part}(G)$.

Exemplo: uma inversão

$$A = \langle +1, +2, +3, +4 \rangle, \quad B = \langle +1, -3, -2, +4 \rangle.$$

$\text{Adj}(A)$	$\text{Adj}(B)$
$\{1^h, 2^t\}$	$\{1^h, 3^h\}$
$\{2^h, 3^t\}$	$\{3^t, 2^h\}$
$\{3^h, 4^t\}$	$\{2^t, 4^t\}$

A adjacência central é preservada. As duas adjacências exclusivas de A são cortadas e as duas exclusivas de B são criadas:

$$2 \text{ cortes} + 2 \text{ junções} = 4.$$

Resultado

$d_{\text{SCJ}}(A, B) = 4$. A SCJ conta alterações individuais de adjacência; por isso uma inversão pode custar quatro operações.

A distância SCJ é a diferença simétrica das adjacências

Teorema

Para genomas sobre o mesmo conjunto de blocos,

$$d_{\text{SCJ}}(A, B) = |\text{Adj}(A) \setminus \text{Adj}(B)| + |\text{Adj}(B) \setminus \text{Adj}(A)| = |\text{Adj}(A) \triangle \text{Adj}(B)|.$$

Limite inferior

Cada SCJ altera a presença de exatamente uma adjacência: **um corte remove uma** e **uma junção adiciona uma**.

Logo, cada elemento da diferença simétrica exige pelo menos uma operação.

Consequência algorítmica

Representando os conjuntos por tabelas hash, a distância é calculada em tempo esperado $O(n)$.

Limite superior

1. corte as adjacências de $\text{Adj}(A) \setminus \text{Adj}(B)$;
2. junte as de $\text{Adj}(B) \setminus \text{Adj}(A)$.

Depois dos cortes, todas as extremidades necessárias às novas adjacências estão livres.

Adjacências presentes geram vetores de tamanho $O(n)$

Considere os genomas $A = \langle +1, +2, +3 \rangle$, $B = \langle +1, -2, +3 \rangle$.

1. Extraia as adjacências

Percorra cada cromossomo e registre as extremidades consecutivas:

$$\text{Adj}(A) = \{ \{1^h, 2^t\}, \{2^h, 3^t\} \},$$

$$\text{Adj}(B) = \{ \{1^h, 2^h\}, \{2^t, 3^t\} \}.$$

2. Uma coordenada por adj

Usamos apenas a união

$$U = \text{Adj}(A) \cup \text{Adj}(B).$$

Fixamos a seguinte ordem:

$$a_1 = \{1^h, 2^t\}, \quad a_2 = \{2^h, 3^t\},$$

$$a_3 = \{1^h, 2^h\}, \quad a_4 = \{2^t, 3^t\}.$$

3. Marque presença ou ausência

Para $G \in \{A, B\}$, defina

$$x_G[j] = \begin{cases} 1, & \text{se } a_j \in \text{Adj}(G), \\ 0, & \text{caso contrário.} \end{cases}$$

Coordenada	Adjacência	x_A	x_B
a_1	$\{1^h, 2^t\}$	1	0
a_2	$\{2^h, 3^t\}$	1	0
a_3	$\{1^h, 2^h\}$	0	1
a_4	$\{2^t, 3^t\}$	0	1

$$x_A = (1, 1, 0, 0), \quad x_B = (0, 0, 1, 1).$$

Distância de Hamming

$$d_H(x_A, x_B) = \sum_{j=1}^4 |x_A[j] - x_B[j]|$$

$$= 1 + 1 + 1 + 1 = 4.$$

$$\text{Logo, } d_H(x_A, x_B) = |\text{Adj}(A) \triangle \text{Adj}(B)| = d_{\text{SCJ}}(A, B).$$

DCJ corta duas partes e reconecta as extremidades

Double-Cut-and-Join

Escolha duas partes de $\text{Part}(A)$, corte-as e forme uma nova partição das extremidades envolvidas em partes de tamanho 1 ou 2.



$$\{p, q\}, \{r, s\} \longrightarrow \{p, r\}, \{q, s\} \quad \text{ou} \quad \{p, s\}, \{q, r\}.$$

A definição DCJ inclui quatro formas de corte e junção

Entrada	Exemplo de saída	Interpretação possível
duas adjacências	$\{p, q\}, \{r, s\} \rightarrow \{p, r\}, \{q, s\}$	inversão ou translocação recíproca
adjacência e telômero	$\{p, q\}, \{r\} \rightarrow \{p, r\}, \{q\}$	mover uma extremidade cromossômica
dois telômeros	$\{p\}, \{q\} \rightarrow \{p, q\}$	fusão ou circularização
uma adjacência	$\{p, q\} \rightarrow \{p\}, \{q\}$	fissão ou linearização

A **interpretação biológica** depende de onde estão as extremidades e de quais cromossomos elas pertencem; a operação combinatória é sempre uma repartição local.

Uma DCJ realiza uma inversão em um cromossomo linear

$$A = \langle +1, +2, +3, +4 \rangle.$$

Para inverter o segmento $(+2, +3)$, corte as adjacências externas:

$$\{1^h, 2^t\}, \quad \{3^h, 4^t\}.$$

Reconecte transversalmente:

$$\{1^h, 3^h\}, \quad \{2^t, 4^t\}.$$



Resultado

$$\langle +1, +2, +3, +4 \rangle \xrightarrow{1 \text{ DCJ}} \langle +1, -3, -2, +4 \rangle.$$

A ordem do segmento é invertida e todos os sinais são trocados.

A mesma operação representa translocação, fusão e fissão

Translocação

$$\langle A B \mid C \rangle$$
$$\langle D E \mid F \rangle$$

Dois cortes em cromossomos distintos e reconexão cruzada trocam os segmentos finais.

Fusão

$$\langle A B \mid \quad \mid C D \rangle$$
$$\Downarrow$$
$$\langle A B C D \rangle$$

Dois telômeros tornam-se adjacentes.

Fissão

$$\langle A B \mid C D \rangle$$
$$\Downarrow$$
$$\langle A B \rangle, \quad \langle C D \rangle$$

Uma adjacência torna-se dois telômeros.

Na forma mais geral, a operação permite duas quebras. Os casos de uma quebra ou apenas uma junção aparecem quando telômeros participam.

SCJ e DCJ contam eventos em escalas diferentes

No exemplo da inversão,

$$A = \langle +1, +2, +3, +4 \rangle, \quad B = \langle +1, -3, -2, +4 \rangle.$$

Modelo	O que conta	Distância
SCJ	cada remoção ou criação individual de adjacência	4
DCJ	a quebra de duas adjacências e sua reconexão como um evento	1

Não existe distância sem modelo


Os mesmos genomas podem ter valores diferentes porque as operações elementares são diferentes.

O grafo de adjacências compara as partes dos dois genomas

Há diferentes convenções para o nome *breakpoint graph*. Usaremos a construção de Bergeron–Mixtacki–Stoye, chamada **grafo de adjacências**.

Definição de $AG(A, B)$

- para cada parte de $\text{Part}(A)$, crie um vértice azul;
- para cada parte de $\text{Part}(B)$, crie um vértice laranja;
- para cada extremidade x , ligue o vértice de A que contém x ao vértice de B que contém x ;
- rotule essa aresta por x .



Todo componente do grafo é um caminho ou um ciclo

Graus dos vértices

- uma adjacência contém duas extremidades: grau 2;
- um telômero contém uma extremidade: grau 1.

Como todos os vértices têm grau 1 ou 2, cada componente conexo é um **caminho** ou um **ciclo**.

O comprimento conta arestas

Cada aresta representa uma extremidade de bloco. Assim, o grafo possui exatamente $2n$ arestas.

Paridade dos caminhos

O grafo é bipartido entre partes de A e de B :

- caminho **ímpar**: extremos em genomas diferentes;
- caminho **par**: extremos no mesmo genoma.

Todos os ciclos possuem comprimento par.

Exemplo: primeiro liste as partes de A e B

$$A = \langle +1, +2, +3, +4 \rangle, \quad B = \langle +1, -3, -2, +4 \rangle.$$

	Part(A)	Part(B)
telômero esquerdo	$\{1^t\}$	$\{1^t\}$
primeira adjacência	$\{1^h, 2^t\}$	$\{1^h, 3^h\}$
segunda adjacência	$\{2^h, 3^t\}$	$\{3^t, 2^h\}$
terceira adjacência	$\{3^h, 4^t\}$	$\{2^t, 4^t\}$
telômero direito	$\{4^h\}$	$\{4^h\}$


Partes já corretas

$$\{1^t\}, \quad \{2^h, 3^t\}, \quad \{4^h\}.$$

Uma adjacência é um conjunto **não ordenado**: $\{2^h, 3^t\} = \{3^t, 2^h\}$.

Cada extremidade cria uma aresta no grafo

Para o exemplo anterior, $AG(A, B)$ se decompõe em quatro componentes:



Contagem

Há $C = 2$ ciclos e $I = 2$ caminhos ímpares. Os caminhos de tamanho 1 e o ciclo de tamanho 2 representam partes já compartilhadas.

Os componentes medem quanto da organização já coincide

No grafo do exemplo:

$$C = 2, \quad l = 2, \quad n = 4.$$

Componentes triviais

- uma **adjacência comum** produz um ciclo de tamanho 2;
- um **telômero comum** produz um caminho de tamanho 1.

O ciclo de tamanho 4 reúne exatamente as quatro extremidades afetadas pela inversão. Uma única DCJ divide esse ciclo em dois ciclos de tamanho 2.

O grafo não registra apenas quantas partes diferem: ele registra como essas diferenças pertencem aos mesmos caminhos e ciclos alternantes.

Ciclos e caminhos ímpares fornecem a distância DCJ

Teorema da distância DCJ

Se A e B possuem o mesmo conjunto de n blocos, sem duplicações, e $AG(A, B)$ possui C ciclos e I caminhos com número ímpar de arestas, então

$$d_{DCJ}(A, B) = n - \left(C + \frac{I}{2} \right).$$

No exemplo,

$$d_{DCJ}(A, B) = 4 - \left(2 + \frac{2}{2} \right) = 1.$$


Em outras palavras: Cada ciclo contribui com 1 e cada par de caminhos ímpares contribui com 1 para a quantidade de estrutura já organizada.

As duas DCJs que produzem progresso máximo

(a) Criar uma adjacência-alvo aumenta o número de ciclos

antes: $C = 1, I = 0$


depois: $C = 2, I = 0$



(b) Criar dois telômeros-alvo aumenta os caminhos ímpares

antes: $C = 0, I = 0$

depois: $C = 0, I = 2$



Cada operação aumenta o potencial em uma unidade


$$\Delta C = +1 \quad \text{ou} \quad \Delta I = +2 \quad \implies \quad \Delta \Phi = \Delta C + \frac{\Delta I}{2} = 1.$$

Uma DCJ de ordenação encurta um caminho ímpar

Considere

$$A = \langle +1, +2, +3 \rangle, \quad B = \langle +1 \rangle, (+2, -3).$$

Mostramos abaixo apenas o caminho de tamanho 5. O caminho trivial associado a 1^t permanece inalterado.



$$C = 0, \quad I = 2, \quad d_{DCJ} = 2.$$

$$C_2 + P_3 \longrightarrow 2C_2 + P_1$$

$$C = 2, \quad I = 2, \quad d_{DCJ} = 0.$$

As duas DCJs

$$\{1^h, 2^t\}, \{2^h, 3^t\} \longrightarrow \{2^t, 3^t\}, \{1^h, 2^h\},$$

$$\{1^h, 2^h\}, \{3^h\} \longrightarrow \{1^h\}, \{2^h, 3^h\}.$$

O que acontece com o caminho ímpar?

Cada DCJ cria uma adjacência de B , extrai um ciclo trivial e reduz o caminho em duas arestas:
 $P_5 \longrightarrow C_2 + P_3 \longrightarrow 2C_2 + P_1$. Em cada passo, $\Delta C = +1$, $\Delta I = 0$, $\Delta \Phi = +1$.

Uma DCJ de ordenação produz o maior avanço possível

Defina o **potencial** $\Phi(A, B) = C + \frac{I}{2}$.

Como uma DCJ altera C ou I , mas não ambos, $\Delta\Phi = \Delta C + \frac{\Delta I}{2} \in \{-1, 0, +1\}$.
Logo, uma única DCJ pode aumentar Φ em, no máximo, uma unidade.

Limite inferior

Se $A = B$ e há m cromossomos lineares, então

$$C = n - m, \quad I = 2m.$$

$$\text{Portanto, } \Phi(B, B) = (n - m) + \frac{2m}{2} = n.$$

Partindo de $\Phi(A, B)$, precisamos obter um aumento total de

$$n - \Phi(A, B).$$

Como cada operação aumenta o potencial em, no máximo, 1,

$$d_{\text{DCJ}}(A, B) \geq n - \left(C + \frac{I}{2}\right).$$

Cada DCJ da ordenação possui $\Delta\Phi = 1$, $d_{\text{DCJ}}(A, B) = n - \left(C + \frac{I}{2}\right).$

Limite superior


Enquanto $A \neq B$, podemos escolher uma DCJ de ordenação:

1. se falta uma adjacência de B , criamos essa adjacência e um novo ciclo trivial: $\Delta C = +1$;
2. quando todas as adjacências de B já existem, separam-se dois telômeros-alvo ainda unidos em A : $\Delta I = +2$.

Nos dois casos, $\Delta\Phi = +1$.

As partes de B já criadas formam componentes triviais e não precisam mais ser modificadas.

Um caminho par registra uma diferença no número de cromossomos



Por que o caminho par não entra em I ?

Um caminho ímpar tem uma extremidade na partição de A e outra na partição de B . Já um caminho par possui as duas extremidades na mesma partição.

Neste exemplo, as duas extremidades estão em B : os telômeros $\{2^h\}$ e $\{3^t\}$ existem em B , mas ainda estão unidos pela adjacência $\{2^h, 3^t\}$ em A . Portanto, ainda não existem dois telômeros correspondentes, um em cada genoma, que possam ser contados como caminhos ímpares.

Aqui, $n = 3$, $C = 1$ e $I = 2$. Assim,

$$d_{DCJ}(A, B) = 3 - \left(1 + \frac{2}{2}\right) = 1.$$

O caminho par não é ignorado

Por não contribuir para I , ele deixa o potencial $\Phi = C + I/2$ uma unidade abaixo de n .

A fissão corta $\{2^h, 3^t\}$ e cria os telômeros $\{2^h\}$ e $\{3^t\}$. O caminho par é substituído por dois caminhos ímpares triviais: $I : 2 \rightarrow 4$, $\Phi : 2 \rightarrow 3 = n$, $d_{DCJ} : 1 \rightarrow 0$.

O grafo também fornece uma ordenação ótima

Considere

$$A = \langle +1, +2, +3, +4 \rangle, \quad B = \langle +1, +2, +4, +3 \rangle.$$

O grafo possui $n = 4$, $C = 1$ e $I = 2$; portanto,

$$d_{\text{DCJ}}(A, B) = 4 - \left(1 + \frac{2}{2}\right) = 2.$$

Como obter uma sequência de ordenação a partir do grafo

Percorremos as partes de B que ainda não aparecem em A .

Para criar uma adjacência-alvo $\{p, q\}$, localizamos as duas partes de A que contêm p e q e aplicamos uma DCJ que passa a ligá-los. Isso separa um novo ciclo trivial no grafo.

Quando restarem apenas telômeros-alvo, cortamos a adjacência que ainda os une, produzindo dois caminhos ímpares triviais.

Cada uma dessas operações aumenta

$$\Phi = C + \frac{I}{2}$$

em exatamente 1 e, portanto, reduz a distância restante em uma unidade, sem destruir as partes de B já construídas.

Distância e ordenação DCJ são lineares no modelo básico

Algoritmo para a distância

1. construa $\text{Part}(A)$ e $\text{Part}(B)$;
2. associe cada extremidade às duas partes que a contêm;
3. percorra $AG(A, B)$ e conte ciclos e caminhos ímpares;
4. devolva $n - (C + I/2)$.

O grafo tem $O(n)$ vértices e exatamente $2n$ arestas. Portanto,

tempo $O(n)$, espaço $O(n)$.

Construção do cenário

Escolhendo em cada componente uma DCJ que aumenta Φ , obtemos uma sequência ótima. Com estruturas de dados apropriadas, o trabalho total também é linear, além da saída das operações.

Com vários genomas, aparecem problemas de consenso diferentes

Dados $G_1, \dots, G_m$ e uma distância genômica d :

Mediana genômica

$$\min_M \sum_{i=1}^m d(M, G_i).$$

Minimiza o número total de eventos. É natural para inferir um ancestral ligado a vários genomas observados.

Uma solução pode reduzir muito a soma favorecendo vários genomas próximos, mas continuar distante de um genoma extremo.

Genoma mais próximo

$$\min_M \max_{1 \leq i \leq m} d(M, G_i).$$

Minimiza a pior distância e procura um centro que não fique excessivamente distante de nenhuma entrada.

Sob SCJ, a mediana de um número ímpar de genomas é a maioria

Sejam $G_1, \dots, G_m$, com m ímpar. Para uma adjacência e , denote por $f(e)$ o número de genomas que a contêm.

Contribuição de e ao custo

- se $e \notin \text{Adj}(M)$, ela contribui $f(e)$;
- se $e \in \text{Adj}(M)$, ela contribui $m - f(e)$.

Logo, escolhemos e precisamente quando

$$m - f(e) < f(e) \iff f(e) > \frac{m}{2}.$$

Por que as adjacências majoritárias são compatíveis?

Se duas adjacências conflitantes usassem a mesma extremidade e ambas aparecessem em mais de $m/2$ genomas, suas frequências somariam mais que m . Mas nenhum genoma pode conter as duas. Contradição.

Assim, as adjacências de maioria estrita formam uma mediana válida e única; as extremidades restantes tornam-se telômeros.

Sob DCJ, distância par a par é fácil, mas mediana é difícil

Problema	Complexidade	Motivo estrutural
distância DCJ entre dois genomas	$O(n)$	um único grafo se decompõe em caminhos e ciclos
ordenação DCJ	$O(n)$	cada operação ótima melhora um componente
mediana DCJ	NP-difícil	a solução precisa ser compatível simultaneamente com vários grafos

Resultado importante

O problema da mediana DCJ é NP-difícil mesmo para três genomas circulares sem duplicações.

Algoritmos exatos empregam *branch-and-bound*, programação inteira e decomposições do grafo; heurísticas e parametrizações tornam-se relevantes para instâncias maiores.

Duplicações e conteúdo desigual mudam o problema

O teorema

$$d_{DCJ}(A, B) = n - \left(C + \frac{I}{2} \right)$$

pressupõe uma correspondência um-a-um entre os blocos dos dois genomas.

O que pode falhar?

- blocos aparecem várias vezes;
- há genes exclusivos de um genoma;
- ocorrem inserções, deleções e duplicações;
- a homologia entre cópias é ambígua.

Consequência computacional

Antes de contar ciclos, pode ser necessário escolher uma correspondência entre cópias ou combinar DCJ com indels. Essa escolha introduz otimização adicional e frequentemente NP-dificuldade.

Referências biológicas e estudos de caso

- NHGRI. *Centromere, Telomere e Chromosome*, Genetics Glossary.
- OpenStax. *Biology 2e*, Sec. 13.2.
- MedlinePlus Genetics. *BCR gene e Chronic Myeloid Leukemia*.
- J. W. Ijdo et al. "Origin of Human Chromosome 2: an Ancestral Telomere-Telomere Fusion". *PNAS*, 1991.
- Y. Fan et al. "Genomic Structure and Evolution of the Ancestral Chromosome Fusion Site in 2q13–2q14.1". *Genome Research*, 2002.
- J. D. Palmer e L. A. Herbon. "Plant Mitochondrial DNA Evolves Rapidly in Structure, but Slowly in Sequence". *J. Mol. Evol.*, 1988.
- S. Hannenhalli e P. A. Pevzner. "Transforming Cabbage into Turnip". *JACM* 46(1), 1999.
- D. Sankoff et al. "Gene Order Comparisons for Phylogenetic Inference". *PNAS* 89, 1992.
- Gao et al. *Molecular Biology and Evolution*, 2022

Referências algorítmicas principais

- A. Bergeron, J. Mixtacki e J. Stoye. "A Unifying View of Genome Rearrangements". *WABI*, 2006.
- S. Yancopoulos, O. Attie e R. Friedberg. "Efficient Sorting of Genomic Permutations by Translocation, Inversion and Block Interchange". *Bioinformatics*, 2005.
- P. Feijão e J. Meidanis. "SCJ: A Breakpoint-Like Distance that Simplifies Several Rearrangement Problems". *IEEE/ACM TCBB*, 2011.
- G. Fertin, A. Labarre, I. Rusu, E. Tannier e S. Vialette. *Combinatorics of Genome Rearrangements*. MIT Press, 2009.
- E. Tannier, C. Zheng e D. Sankoff. "Multichromosomal Median and Halving Problems under Different Genomic Distances". *BMC Bioinformatics*, 2009.
- M. Zhang et al. "An Exact Solver for the DCJ Median Problem". *Pacific Symposium on Biocomputing*, 2009.
- M. D. V. Braga, E. Willing e J. Stoye. "Genomic Distance with DCJ and Indels". *WABI*, 2010.
- L. F. I. Cunha et al. "On the Computational Complexity of Closest Genome Problems". *Theoretical Computer Science*, 2020.